PROYECTO DE TÍTULO · VISIÓN COMPUTACIONAL

Detección de espacios vacíos en góndolas de supermercado

Evaluación de YOLOv8s en imágenes limpias y degradadas para simular condiciones de cámaras de seguridad

Informe de resultados experimentales

Estudiantes: david salvatierra, david yañes,francisco merino, francisco fernandez Fecha: 07/11/2026

Objetivo y diseño experimental

Evaluar la detección de productos y espacios vacíos bajo condiciones de imagen distintas.

OBJETIVO

Detectar dos clases en imágenes de góndolas:

- product: productos en repisa
- missing: espacios vacíos

CONFIGURACIÓN DEL MODELO

YOLOv8s preentrenado · imgsz 640 · 100 épocas

Batch 16 · seed 42 · 10 capas iniciales congeladas

Entrenamiento con aumentación aplicada solo a train

MODELO	RESOLUCIÓN	UMBRAL CONF.	HARDWARE
YOLOv8s	640 px	0,38	T4 GPU
11.136.374 parámetros	Lado máximo de entrada	Máximo F1 medio en validación	Entorno Colab reportado

Dataset y partición

349 imágenes originales; grupos casi duplicados considerados durante la partición.

IMÁGENES ORIGINALES

349

Lado máximo reducido a 960 px

TRAIN

243

69,6% · 994 cajas missing

VALIDACIÓN

53

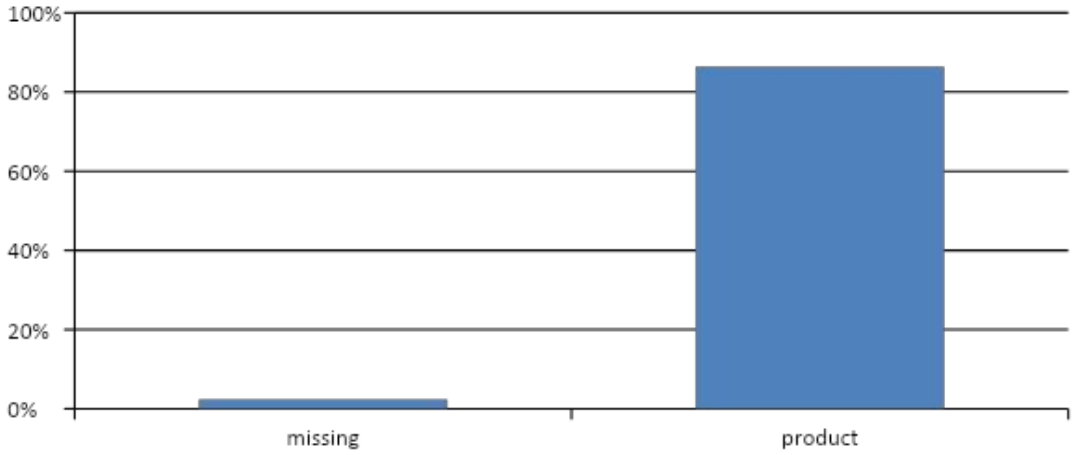
15,2% · 211 cajas missing

TEST

53

15,2% · 211 cajas missing

DESBALANCE DE CLASES EN EL DATASET ORIGINAL



1.416 cajas missing frente a 51.862 product (≈36,6 veces más product).

Train se amplió mediante aumentación: 243 originales + 1.352 aumentadas = 1.595 imágenes.

Resultados generales · conjunto test

Comparación del conjunto de prueba limpio frente a su versión degradada test_cam.

PRECISIÓN · LIMPIO

69,2%

Test

RECALL · LIMPIO

62,9%

Test

MAP50 · LIMPIO

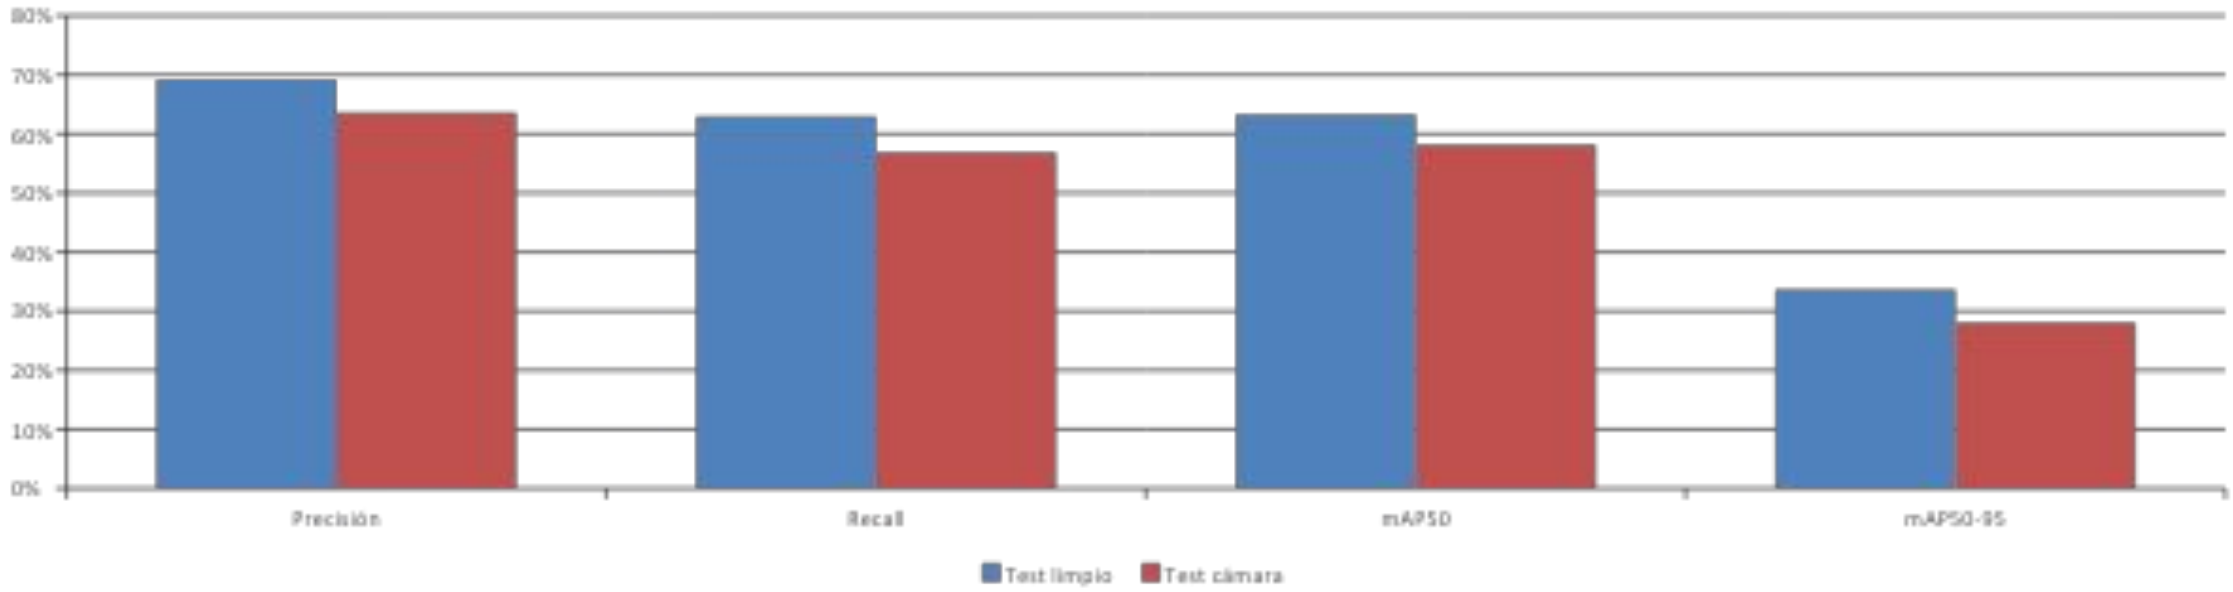
63,3%

Test

MAP50-95 · LIMPIO

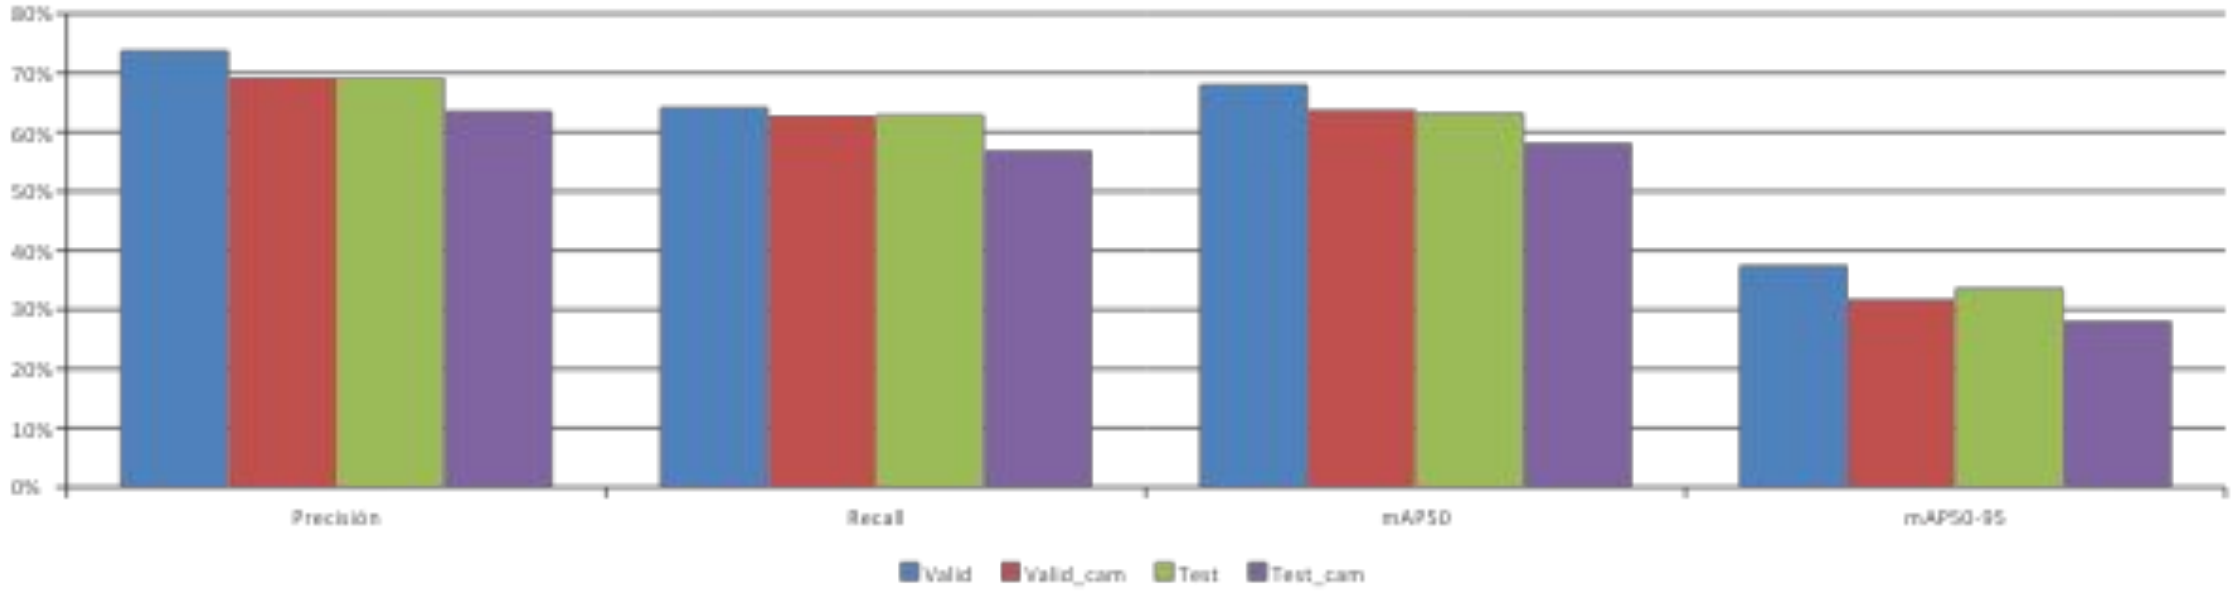
33,6%

Test



Validación y test · lectura conjunta

Los resultados de validación sirven para seleccionar parámetros; test se reserva para la evaluación final.

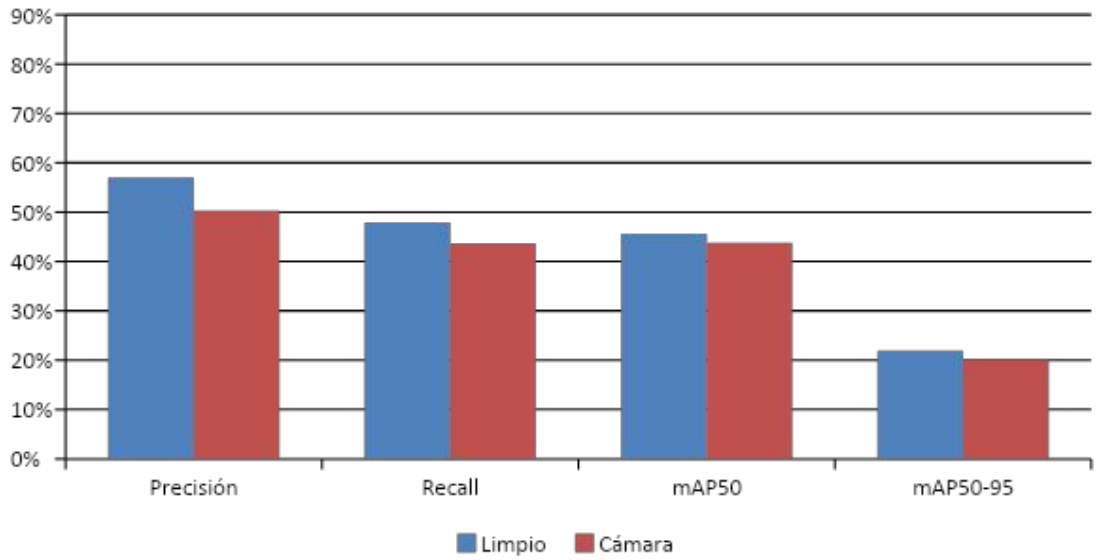


La confianza 0,38 se eligió porque maximiza el F1 medio en validación (F1 = 0,688). F1 por clase: missing 0,551 con conf. 0,38; product 0,826 con conf. 0,43.

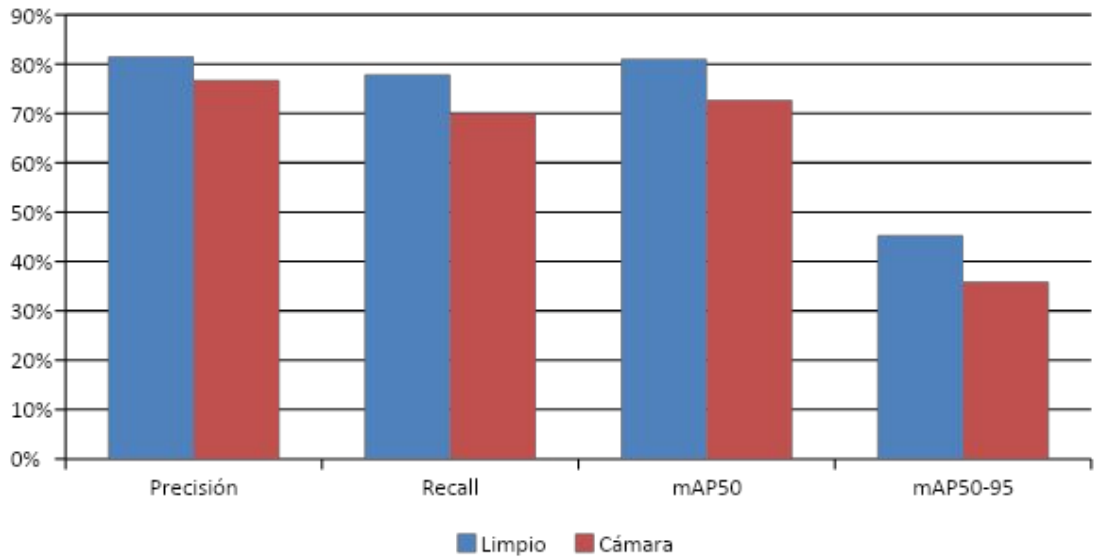
Rendimiento por clase · test

La clase missing presenta menor precisión, recall y mAP que product.

MISSING · ESPACIOS VACÍOS



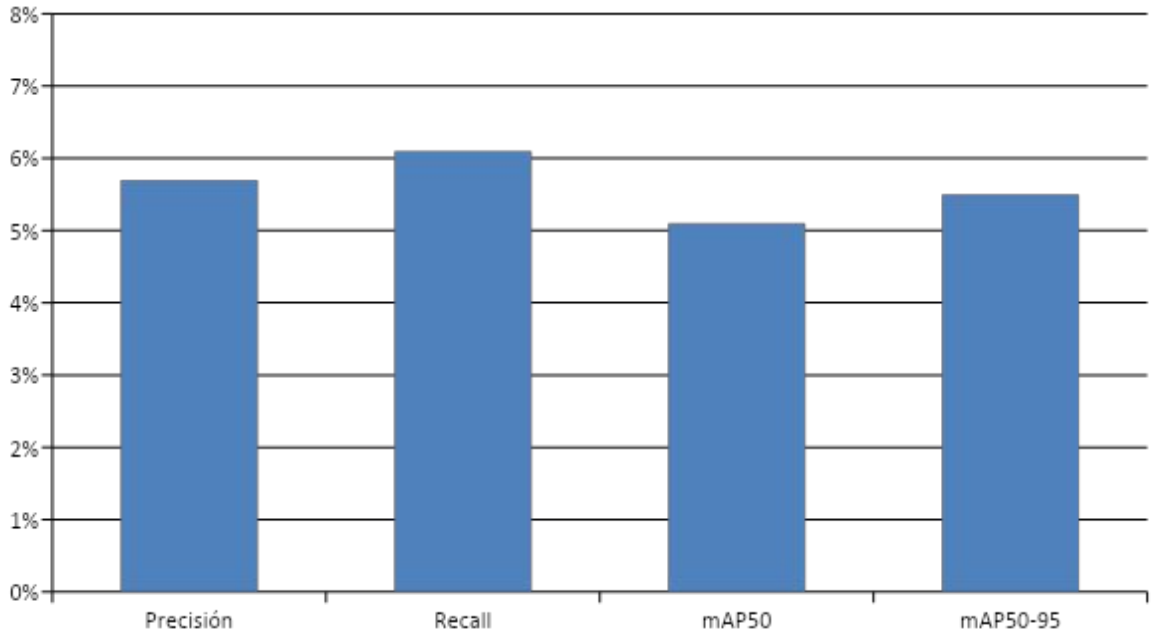
PRODUCT · PRODUCTOS



En test limpio, el recall de missing es 47,9%: el modelo no recupera todos los espacios vacíos reales. La clase product alcanza 77,9% de recall.

Sensibilidad a la degradación

Diferencia entre test limpio y test_cam expresada en puntos porcentuales.



LECTURA

- Precisión: −5,7 pp
- Recall: −6,1 pp
- mAP50: −5,1 pp
- mAP50-95: −5,5 pp

La degradación sintética evidencia sensibilidad a cambios de calidad de imagen. No equivale a una validación con cámaras reales ni permite cuantificar por sí sola el desempeño operacional.

Tamaño de cajas y resolución

Tamaño del lado menor tras redimensionar a 640 px.

PRODUCT < 8 PX

5,6%

Lado menor de caja

PRODUCT < 16 PX

42,5%

Lado menor de caja

PERCENTIL 5

7,7 px

Lado menor de product

MEDIANA

17,5 px

Product

ESCALAS DE PREDICCIÓN

P3 · stride 8 · grid 80 × 80

P4 · stride 16 · grid 40 × 40

P5 · stride 32 · grid 20 × 20

INTERPRETACIÓN Y PROPUESTA

El notebook advierte que algunos objetos pequeños pueden ser difíciles de detectar, pero aclara que la capacidad del grid no es el límite por sí sola. Como trabajo futuro: probar imgsz 800/960 o inferencia por tiles (SAHI).

Experimento complementario · SAM

Prueba exploratoria de máscaras usando cajas como prompts.

TIEMPO PROMEDIO	COVERAGE MEDIANA	LEAK MEDIANA	COLAPSO
503 ms	71,9%	9,7%	2%
Por imagen · sam_b · GPU T4	Test · test_cam 77,5%	Test · test_cam 9,0%	Máscaras

VEREDICTO DEL NOTEBOOK: NO CONCLUYENTE

No se encontraron polígonos de verdad terreno en GT_SEG_DIR. La Prueba A solo revisa fallas evidentes (coverage y leak); por tanto, no mide si SAM mejora la delimitación real. Se propone anotar ~20 polígonos y comparar IoU de SAM contra la anotación. 503 ms equivale a ~2 imágenes/s si se procesa secuencialmente.

Análisis de errores · test_cam

53 imágenes evaluadas por F1 por imagen; emparejamiento de cajas con IoU ≥ 0,5.

MEJOR PUNTAJE

0,978

Imagen 57_jpg

PEOR PUNTAJE

0,165

Imagen 1421_jpg

CASOS EXPORTADOS

10 + 10

Mejores y peores

QUÉ MUESTRAN LOS CASOS

En varios peores casos, missing_F1 = 0 por espacios reales no detectados o falsos positivos. Revisar cajas reales frente a predicciones para identificar patrones visuales.

ADVERTENCIA TÉCNICA DEL ENTRENAMIENTO

Ultralytics emitió una advertencia: max_det=500, mientras el dataset contiene imágenes con hasta 503 objetos en train. Este límite podría truncar predicciones y afectar recall. Conviene repetir evaluación con max_det mayor y documentar el cambio.

Conclusiones y trabajo futuro

Síntesis para la discusión académica.

CONCLUSIONES

1. YOLOv8s reconoce product mejor que missing.
2. test_cam reduce las métricas generales entre 5,1 y 6,1 pp.
3. El desbalance de clases y los objetos pequeños son factores relevantes a investigar.
4. SAM queda como experimento no concluyente.

TRABAJO FUTURO

- Validar con video y cámaras reales.
- Aumentar diversidad de imágenes y ejemplos missing.
- Probar imgsz 800/960 o SAHI.
- Repetir evaluación con max_det adecuado.
- Anotar polígonos para evaluar SAM.

Limitaciones: dataset de 349 imágenes originales; test_cam es una degradación sintética; los resultados no demuestran todavía desempeño operacional en una instalación real.