Computer Vision Walmart (CVW)

Sistema de Monitoreo de Disponibilidad en Góndolas

CVW propone transformar imágenes de góndolas en señales operativas para apoyar la reposición y el monitoreo de disponibilidad en Walmart Chile.
Validación técnica experimental del prototipo.

David E. Salvatierra · David Yáñez · Francisco I. Fernández · Francisco J. Merino

Ingeniería en Informática · Duoc UC · Padre Alonso de Ovalle
Noviembre 2026



La góndola vacía es una señal operativa

Disponibilidad ≠ inventario

Un espacio vacío puede indicar quiebre de stock o reposición pendiente. La inspección manual introduce demoras, variabilidad y errores en una operación de alta frecuencia.

El objetivo es identificar señales visuales de disponibilidad: productos presentes y espacios que requieren revisión, no contabilizar el inventario total.

OPORTUNIDAD

Monitoreo visual continuo como apoyo — no reemplazo — del proceso operativo.



El valor se distribuye a través de la tienda

Reposición + logística

Detección rápida

Supervisión

Monitoreo visual

Clientes

Disponibilidad indirecta

Operaciones + TI

Innovación con IA

La información puede apoyar decisiones de reposición, supervisión y mejora operacional, manteniendo a las personas como responsables de la decisión final.

De imagen a alerta accionable

Detectar productos y faltantes, calcular indicadores y generar alertas.

La cadena de valor es directa: observar la góndola, interpretar detecciones, calcular disponibilidad y alertar cuando la condición sea crítica.

1
Preparar y aumentar datos

2
Entrenar y evaluar YOLO

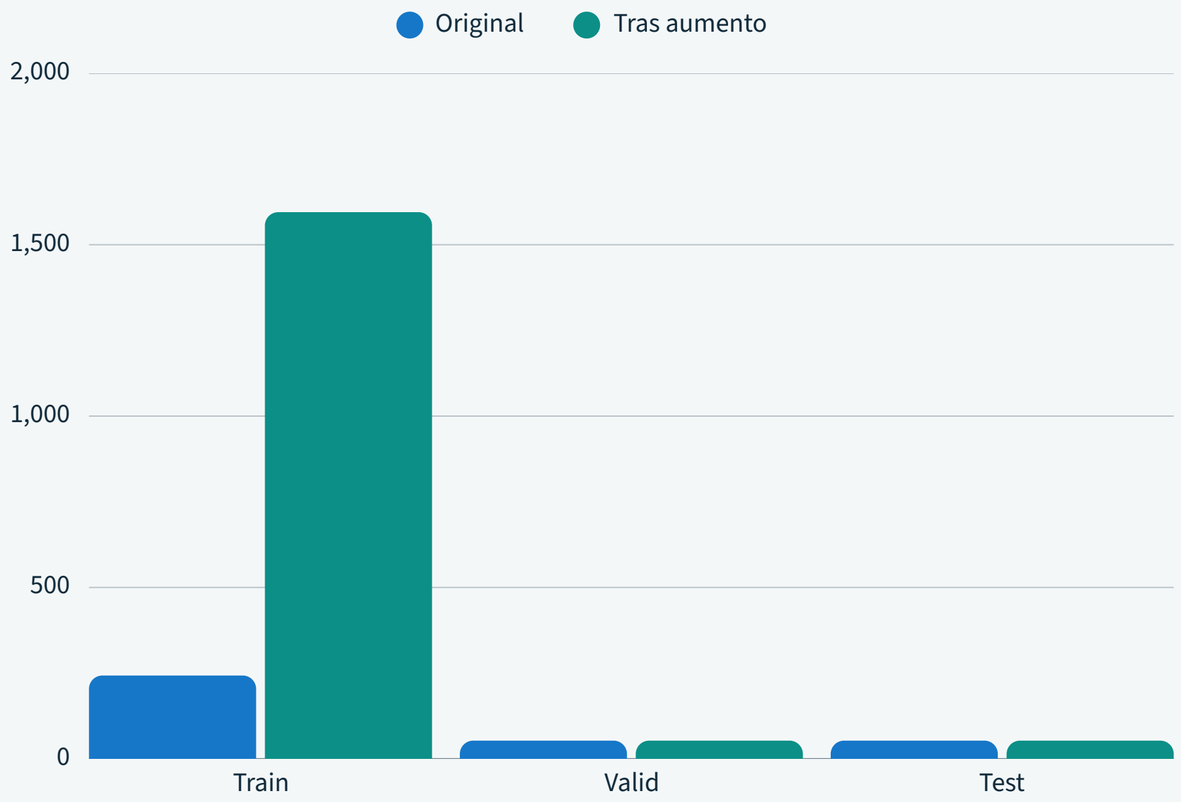
3
Integrar arquitectura modular

4
Construir interfaz web

5
Probar y evaluar continuamente

Datos pequeños; iteración disciplinada

La partición por similitud perceptual y la aumentación exclusiva de train buscan reducir evaluaciones artificialmente optimistas y mejorar la robustez experimental.



MÉTODO

Scrum · iterativo · incremental

DATASET

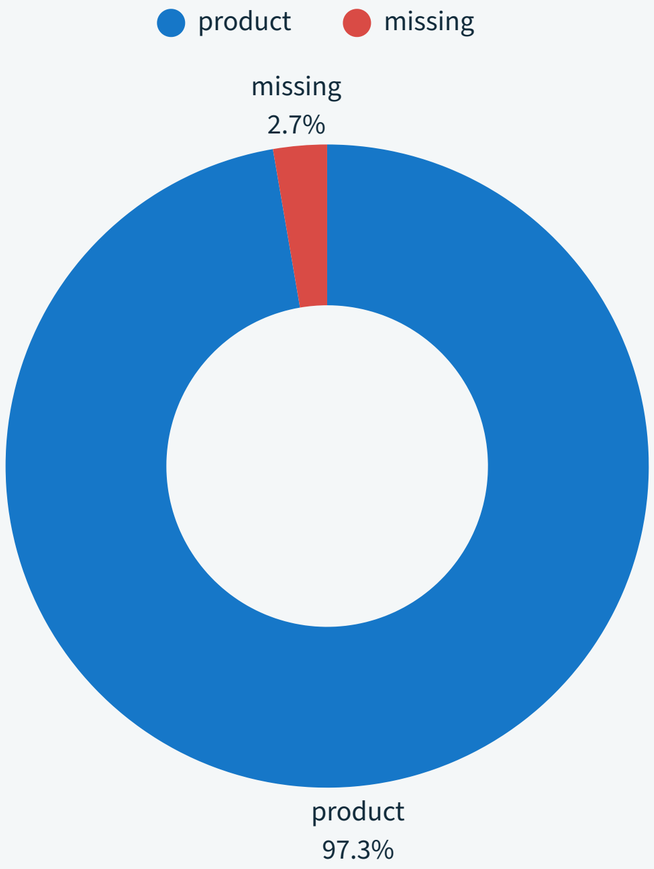
349 imágenes originales

ROBUSTEZ

valid_cam + test_cam degradados

El reto está en la escala y el desbalance

El desbalance es central: el modelo observa muchas más instancias product que missing, precisamente la clase más relevante para activar alertas.



ANOTACIONES

53.278

DESBALANCE

≈37 product / missing

LADO < 8 px

5,6%

LADO < 16 px

42,5%

MEDIANA

17,5 px

P3 · P4 · P5

Escalas de detección YOLOv8

YOLOv8s v2: configuración reproducible

ARQUITECTURA

11,14 M parámetros

ENTRENAMIENTO

640 px · 100 épocas · batch 16

EJECUCIÓN

Tesla T4 · ≈46 min

La configuración busca reproducibilidad y un equilibrio entre capacidad de detección y costo computacional, manteniendo constantes los principales parámetros del experimento.

Entrada
640^2

Backbone
10 capas freeze

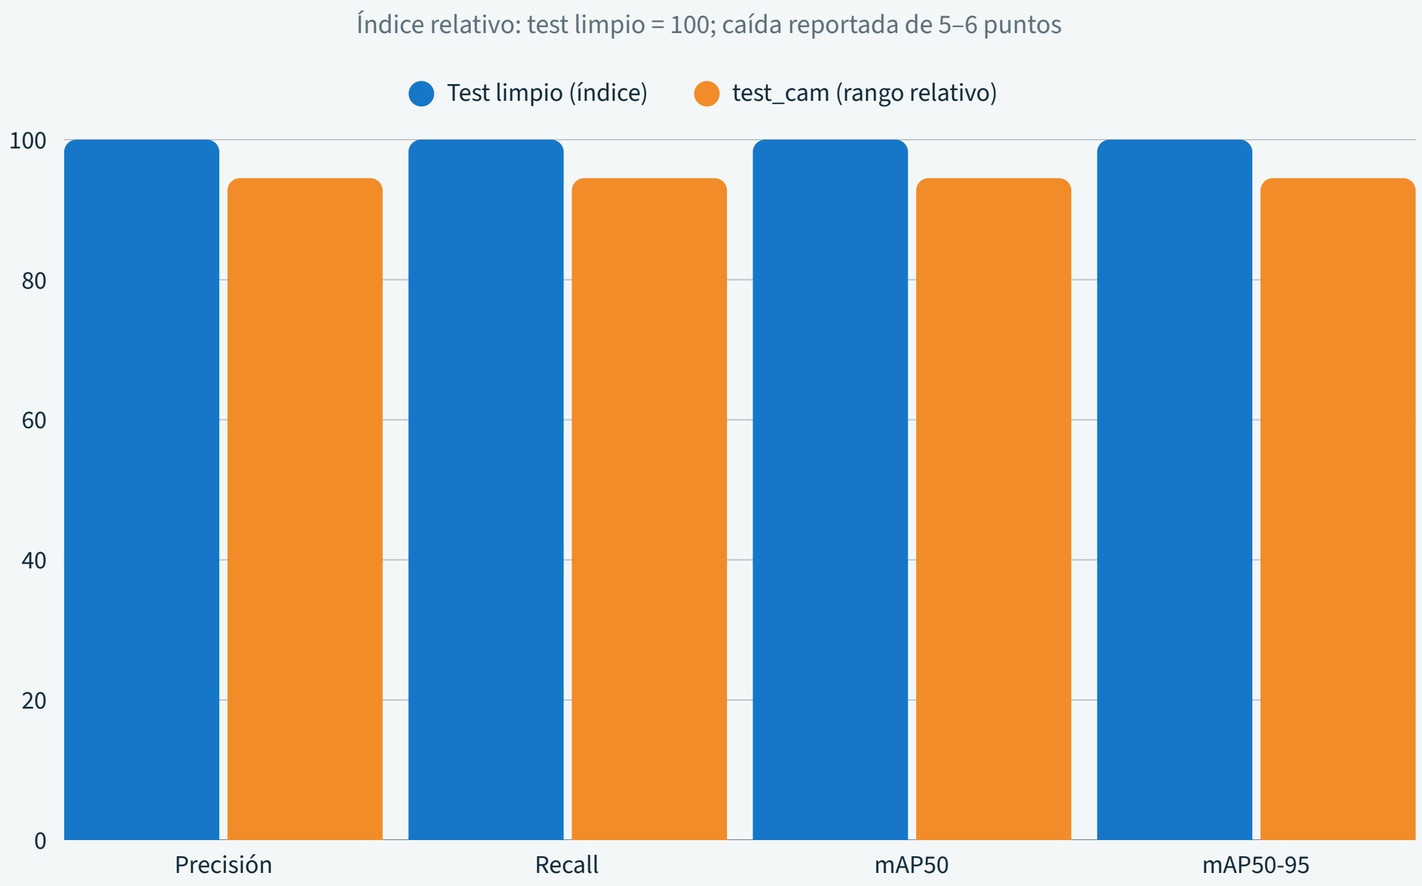
Neck
P3 · P4 · P5

Head
max_det 500

`conf = 0,38 → F1 medio máx. = 0,688 · seed 42 · cls = 1,0`

La degradación sintética reduce el desempeño

En imágenes limpias el desempeño es moderado; al degradar las mismas imágenes, todas las métricas disminuyen entre 5,1 y 6,1 puntos porcentuales.



BRECHA TEST_CAM

−5 a −6 puntos

Cautela: la degradación es sintética. El resultado indica sensibilidad, no desempeño validado en cámaras reales.

missing concentra la principal brecha



Producto visible no equivale a espacio vacío

product lidera todas las métricas. missing cae bajo 50% de recall en test limpio y disminuye aún más en test_cam.

La brecha es operacionalmente relevante: detectar productos no equivale a detectar espacios vacíos, la señal necesaria para priorizar reposición.

Más capacidad no demuestra superioridad

El mayor número de parámetros no demuestra por sí mismo una mejora. La comparación válida exige mismo dataset, partición y protocolo de evaluación.

	YOLOv8n	YOLOv8s v2
Parámetros	≈3 M	11,14 M
Dataset	v3 · ≈200 imgs	v4 · 349 imgs
Contexto	Experimento previo	Configuración actual
Comparabilidad		No directa

Conclusión válida solo con mismos datos, particiones, hiperparámetros y protocolo de evaluación.

La escena explica los extremos

Los errores se concentran cuando la imagen pierde calidad o el fondo se parece a un espacio vacío; los casos extremos complementan las métricas promedio.



MEJOR CASO · frontal + buena luz

F1 0,978

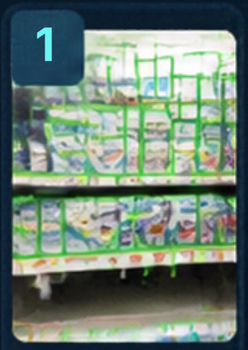


PEOR CASO · sombras + oblicuo

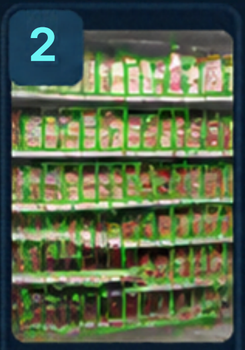
F1 0,165

10 mejores casos · desempeño del nuevo modelo

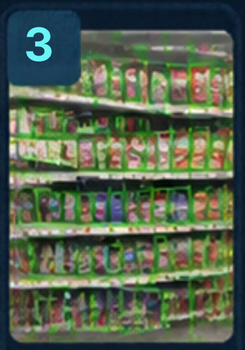
YOLOv8s v2 evaluado sobre test_cam; ordenados por puntaje F1 por imagen



57.jpg



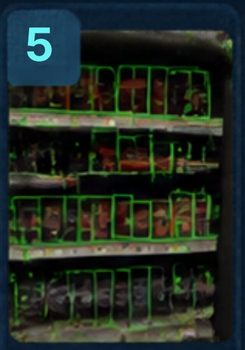
490.jpg



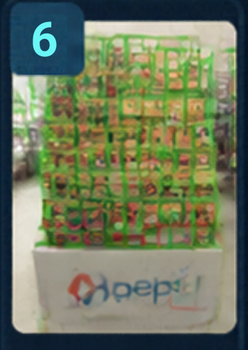
train_46>g



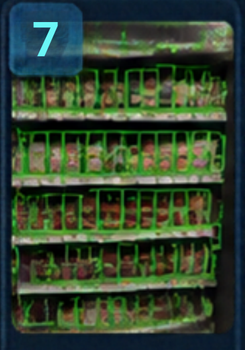
train_4679.jpg



train_4861.jpg



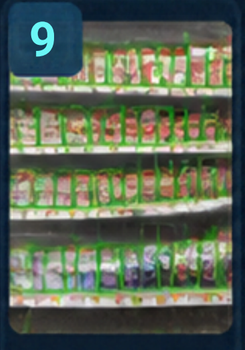
463.jpg



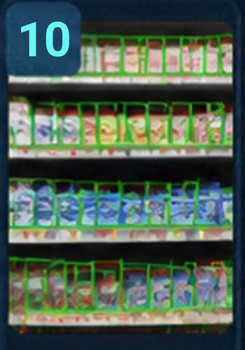
train_4741.jpg



¡¡08_25.jpg



1025.jpg



train_3619.jpg

#	Imagen	F1 total	F1 product	F1 missing	Prod. reales (aciertos)	Missing reales (aciertos)
1	57.jpg	0,978	0,957	1,000	187 (178)	1 (1)
2	490.jpg	0,924	0,848	1,000	116 (112)	2 (2)
3	train_4679.jpg	0,885	0,913	0,857	146 (132)	8 (6)
4	1132.jpg	0,858	0,858			
5	train_4861.jpg	0,849	0,849			
6	463.jpg	0,820	0,871	0,769	121 (115)	5 (5)
7	train_4741.jpg	0,812	0,823	0,800	215 (170)	6 (4)
8	708.jpg	0,805	0,805			
9	1025.jpg	0,799	0,932	0,667	144 (130)	1 (1)
10	train_3619.jpg	0,786	0,786			

Los mejores casos se concentran en escenas con góndola visible, iluminación suficiente y productos claramente delimitados. El alto puntaje global no elimina la necesidad de revisar especificamente la clase missing.

10 peores casos – dónde falla el nuevo modelo

YOLov8s v2 evaluado sobre test_cam; ordenados por puntaje F1 por imagen

Caso 1



Caso 10

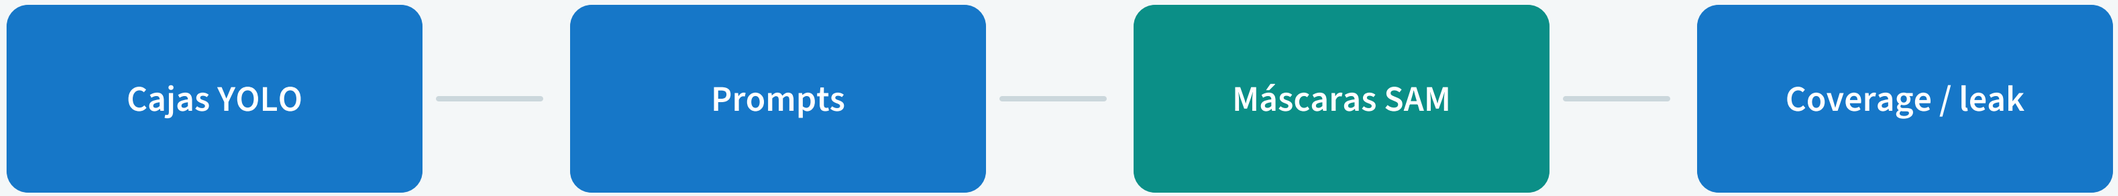


Nº	Caso	F1 total	F1 product	F1 missing	Resultado principal
1	train_4302.jpg	0,344	0,355	0,333	210 productos reales, 52 aciertos; 3 espacios missing reales, 1 acierto.
2	train_4101.jpg	0,342	0,684	0,000	229 productos reales, 130 aciertos; 6 espacios missing reales, 0 aciertos.
3	train_4641.jpg	0,336	0,673	0,000	181 productos reales, 112 aciertos; 9 espacios missing reales, 0 aciertos.
4	319.jpg	0,312	0,624	0,000	210 productos reales, 131 aciertos; 6 espacios missing reales, 0 aciertos.
5	1459.jpg	0,253	0,505	0,000	162 productos reales, 71 aciertos; 2 espacios missing reales, 0 aciertos.
6	995.jpg	0,246	0,491	0,000	193 productos reales, 85 aciertos; 1 espacio missing real, 0 aciertos.
7	train_4683.jpg_17	0,214	0,429	0,000	127 productos reales, 42 aciertos; 2 espacios missing reales, 0 aciertos.
8	train_4683.jpg_842	0,184	0,368	0,000	127 productos reales, 37 aciertos; 1 espacio missing real, 0 aciertos.
9	train_4026.jpg	0,177	0,354	0,000	320 productos reales, 79 aciertos; 2 espacios missing reales, 0 aciertos.
10	1421.jpg	0,165	0,329	0,000	173 productos reales, 40 aciertos; sin espacios missing reales reportados.

Lectura: los peores resultados se concentran en escenas complejas, con baja recuperación de productos y, en la mayoría de los casos, recall nulo para missing. Son resultados del conjunto experimental test_cam y no demuestran desempeño operacional en Walmart Chile.

SAM: exploración útil, evidencia insuficiente

SAM mostró potencial exploratorio, pero no existe evidencia suficiente para afirmar una mejora de segmentación: faltan polígonos de referencia para comparar mediante IoU.

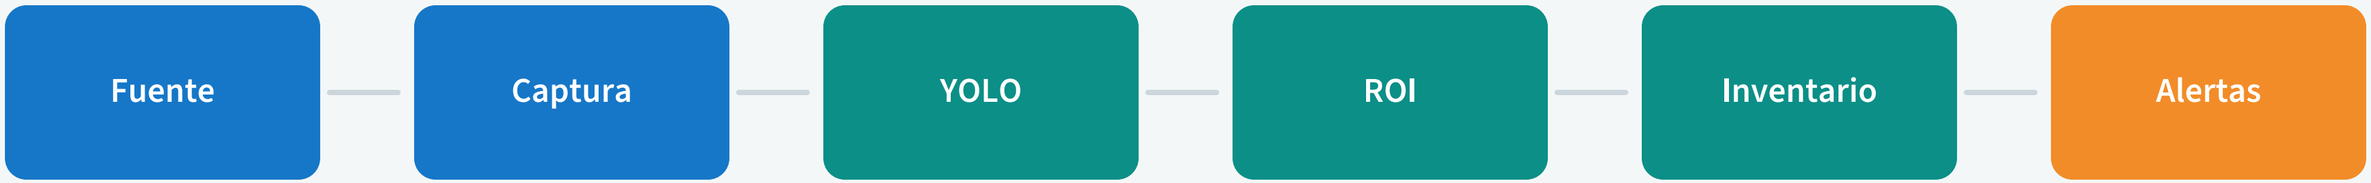


LATENCIA	COVERAGE MEDIANA	LEAK MEDIANA	MÁSCARAS COLAPSADAS
503 ms · 2 img/s	71,9% / 77,5%	9,7% / 9,0%	2%

No integrado al flujo principal: sin polígonos GT no hay conclusión robusta. Próximo paso: anotación y evaluación IoU.

Arquitectura modular, regla explícita

La arquitectura conecta la captura con una decisión operacional: detectar, filtrar, estimar disponibilidad y alertar solo cuando la condición se mantiene durante el tiempo definido.



BACKEND

Python · FastAPI · servicios

FRONTEND

React · TypeScript · Tailwind

FUENTES

webcam · USB · RTSP · sintética

```
ALERTA = missing ≥ 80% durante 3 s  +  cooldown 30 s
```

Decisiones conscientes; riesgos abiertos

Antes de cualquier piloto deben resolverse el desbalance, la sensibilidad visual y la advertencia max_det. Las pruebas automatizadas protegen la evolución del sistema.

Cambio técnico

Segmentación → cajas

Riesgo de recall

max_det 500 vs hasta 503 objetos

Datos

Desbalance + diversidad limitada

Robustez

Sensibilidad visual adversa

Pytest ✓ inventario ✓ ROI ✓ alertas temporales ✓ cooldown ✓ gestión de modelos

Una base experimental, no un producto operativo

CVW deja una base funcional y documentada. La brecha central sigue siendo missing, agravada por degradación visual y el límite max_det.

CVW deja una base funcional para continuar la investigación, pero la validación con cámaras y videos reales de Walmart Chile es el paso previo a evaluar una implementación operacional.

Siguiente evidencia necesaria

- Más datos y cámaras reales
- imgsz 800/960 + SAHI
- max_det superior
- Comparación controlada n vs s
- SAM con polígonos e IoU
- Canal y criterio de notificación



Gracias · Walmart Chile × Duoc UC